HR CASE STUDY - Riccardo Bedogni - 214770

1 Introduzione

Una grande azienda, chiamata XYZ, impiega stabilmente circa 4000 dipendenti. Tuttavia, ogni anno si registra un tasso di turnover pari a circa il 15%, il che significa che una quota significativa della forza lavoro lascia l'azienda e deve essere sostituita con nuovo personale proveniente dal mercato del lavoro. Questo fenomeno include sia dimissioni volontarie sia cessazioni dovute a licenziamenti o mancati rinnovi contrattuali. Secondo il management, un livello di turnover così elevato rappresenta un fattore critico che incide negativamente sull'efficienza complessiva e sulla competitività dell'azienda.

In particolare, l'uscita frequente di dipendenti comporta interruzioni e rallentamenti nei progetti in corso, poiché le attività assegnate devono essere redistribuite o sospese in attesa di nuove assunzioni. Questo rende più difficile rispettare le scadenze pianificate, aumentando il rischio di ritardi nelle consegne e di conseguenti ripercussioni sulla reputazione dell'azienda nei confronti di clienti, partner e stakeholder. Inoltre, la perdita di personale esperto implica spesso anche una dispersione di competenze e conoscenze tacite, che non sono facilmente trasferibili ai nuovi assunti.

Un ulteriore impatto significativo riguarda i costi organizzativi ed economici associati al turnover. L'azienda è costretta a mantenere un reparto di recruiting di dimensioni rilevanti, dedicato alla selezione, valutazione e assunzione continua di nuovi dipendenti. A questi costi diretti si aggiungono quelli indiretti legati ai processi di onboarding e formazione, poiché i nuovi assunti necessitano di tempo per acquisire le competenze tecniche richieste e per integrarsi efficacemente nei team di lavoro e nella cultura aziendale. Durante questa fase, la produttività individuale e collettiva risulta spesso inferiore rispetto a quella di dipendenti più esperti.

Alla luce di queste considerazioni, il management ha deciso di affidarsi a una società specializzata in HR analytics con l'obiettivo di comprendere in modo sistematico le cause principali del turnover. In particolare, l'azienda desidera identificare i fattori lavorativi, organizzativi e personali che influenzano maggiormente la decisione dei dipendenti di lasciare l'azienda, così da poter intervenire in maniera mirata. L'obiettivo finale è definire strategie e politiche aziendali in grado di migliorare la soddisfazione, il coinvolgimento e la fidelizzazione dei dipendenti, riducendo il tasso di turnover nel medio-lungo periodo. Inoltre, il management intende individuare le variabili più rilevanti e urgenti su cui agire, al fine di allocare in modo efficace le risorse e ottenere benefici concreti nel minor tempo possibile.

---

2 Scopi e Obiettivi

È richiesto di modellare la probabilità di turnover (attrition) dei dipendenti mediante l'utilizzo di modelli di classificazione supervisionata. In particolare, la regressione logistica viene adottata come modello di riferimento, in quanto particolarmente adatta a stimare la probabilità di eventi binari, come la permanenza o l'uscita di un dipendente dall'azienda, e a fornire risultati facilmente interpretabili. L'obiettivo è analizzare la relazione tra il turnover e un insieme di variabili esplicative di natura demografica, professionale e organizzativa, al fine di individuare i fattori che influenzano maggiormente la decisione dei dipendenti di lasciare l'azienda.

Accanto alla regressione logistica, vengono inoltre implementati e confrontati modelli di machine learning più complessi, tra cui Decision Tree, Random Forest, K-Nearest Neighbors e XGBoost, con lo scopo di valutarne le prestazioni predittive e confrontarle in termini di accuratezza e capacità di generalizzazione. Questo confronto permette di bilanciare l'esigenza di interpretabilità del modello con il miglioramento delle performance predittive.

Infine, al fine di aumentare la trasparenza dei modelli e validare l'importanza delle variabili utilizzate, viene applicata la tecnica SHAP (SHapley Additive exPlanations). L'analisi SHAP consente di interpretare le previsioni dei modelli individuando il contributo di ciascuna feature alla probabilità di attrition, sia a livello globale sia a livello del singolo dipendente. Questo approccio permette di verificare la coerenza dei risultati ottenuti, identificare in modo robusto le variabili più rilevanti e fornire al management indicazioni affidabili e facilmente interpretabili sui principali fattori che influenzano il turnover.

3 Background e analisi della letteratura

3.1 Il contesto del turnover aziendale

Il turnover dei dipendenti, o attrition, rappresenta una delle sfide più critiche per la gestione delle risorse umane nelle grandi organizzazioni moderne. In letteratura, il fenomeno è definito come la cessazione dell'impiego da parte di un lavoratore e la sua conseguente sostituzione. Sebbene un certo grado di ricambio fisiologico sia naturale, tassi elevati di turnover non pianificato comportano costi significativi per le aziende, sia diretti che indiretti.

I costi diretti includono le spese per il reclutamento, la selezione e l'inserimento (onboarding) di nuovo personale. Tuttavia, spesso sono i costi indiretti a impattare maggiormente sulla competitività aziendale: la perdita di know-how istituzionale, l'interruzione dei flussi di lavoro nei team, i ritardi nei progetti critici e il potenziale calo della reputazione aziendale presso clienti e partner. Nel caso specifico oggetto di studio, l'azienda XYZ affronta un tasso di abbandono annuale del 15%, un livello che il management ha identificato come insostenibile a causa delle ripercussioni operative e finanziarie.

3.2 L'evoluzione verso l'HR Analytics

Tradizionalmente, le strategie di retention (trattenimento dei talenti) si basavano sull'intuizione dei manager o su approcci reattivi, intervenendo spesso quando la decisione del dipendente era già irreversibile. Negli ultimi anni, si è assistito a un cambio di paradigma con l'avvento della People Analytics o HR Analytics. Questo approccio applica tecniche di Data Mining e Machine Learning ai dati del personale per trasformare le risorse umane in una funzione basata sui dati (data-driven).

L'obiettivo non è più solo descrittivo (capire chi se ne è andato), ma predittivo e prescrittivo: utilizzare algoritmi di classificazione per stimare la probabilità di abbandono di ciascun dipendente e identificare i fattori latenti — come il carico di lavoro, la frequenza dei viaggi o la stagnazione della carriera — che contribuiscono maggiormente alla decisione di lasciare l'azienda. Questo studio si inserisce in tale filone di ricerca, proponendo un framework analitico per modellare l'attrition e fornire al management leve decisionali concrete.

3.3 Algoritmi di Classificazione Supervisionata

Per affrontare il problema del turnover, che si configura come un compito di classificazione binaria (prevedere se un dipendente appartiene alla classe "Yes" o "No" rispetto all'attrition), la letteratura scientifica propone diversi approcci. Un punto di partenza standard è rappresentato dalla Regressione Logistica, un modello lineare che offre un'eccellente interpretabilità ma che spesso fatica a catturare le relazioni complesse e non lineari tipiche del comportamento umano. Per superare questi limiti, lo stato dell'arte si è spostato verso metodi Ensemble, che combinano le previsioni di più "modelli deboli" per ottenere un risultato robusto. In particolare:

- **Random Forest:** un approccio di tipo Bagging che costruisce una moltitudine di alberi decisionali durante l'addestramento. È particolarmente efficace nel ridurre il rischio di overfitting (sovradattamento ai dati di training) e nel gestire dataset con variabili miste (numeriche e categoriche).
- **XGBoost (eXtreme Gradient Boosting):** un algoritmo di tipo Boosting che costruisce i modelli in sequenza, dove ogni nuovo modello cerca di correggere gli errori commessi dai precedenti. È noto per le sue prestazioni elevate e la velocità di esecuzione, ed è spesso l'algoritmo vincente nelle competizioni di data science su dati tabulari.

3.4 Explainable AI (XAI) e Interpretabilità

L'adozione di modelli complessi come XGBoost o Random Forest comporta spesso il problema della "Black Box": i modelli offrono previsioni molto accurate, ma la logica interna è oscura per l'essere umano. Nel contesto delle Risorse Umane, dire a un manager che un dipendente ha il "90% di probabilità di licenziarsi" non è sufficiente; è fondamentale spiegare perché (es. a causa delle troppe ore di straordinario o della mancata promozione). Per colmare questo divario, questo studio utilizza i valori SHAP. Derivati dalla teoria dei giochi, i valori SHAP assegnano a ogni feature un valore di importanza per una specifica previsione, permettendo di capire non solo quali variabili sono importanti globalmente, ma anche come influenzano positivamente o negativamente la probabilità di abbandono per il singolo individuo.

4 Metodologie

La metodologia adottata in questo studio segue una pipeline di Data Science standardizzata, composta da quattro fasi principali:

(1) **Esplorazione dei dati**
(2) **Pre-processing e pulizia dei dati**
(3) **Feature Engineering avanzata sui log temporali**
(4) **Addestramento e valutazione comparativa di modelli di Machine Learning**

4.1 Esplorazione dei dati

L'analisi esplorativa (EDA) è stata condotta preliminarmente sulle diverse fonti dati (dati anagrafici, survey e log) per comprendere la distribuzione delle variabili e identificare potenziali correlazioni con la variabile target *Attrition*.

In prima istanza, è stata calcolata una **matrice di correlazione** sulle variabili numeriche, visualizzata tramite Heatmap. Questo passaggio è stato fondamentale per rilevare eventuali multicollinearità tra le feature e identificare le prime relazioni lineari significative.

Successivamente, l'indagine si è spostata sull'analisi bivariata utilizzando **Violin Plots** e grafici a barre per osservare le distribuzioni condizionate. Questa fase ha fatto emergere pattern comportamentali distintivi:

- **Business Travel:** I dipendenti con una frequenza di viaggio elevata (*Travel_Frequently*) mostrano tassi di abbandono sensibilmente superiori rispetto ai colleghi stanziali.
- **Demografia e Anzianità:** I dati evidenziano che i dipendenti più giovani, con stato civile "Single" e con una minore anzianità aziendale (*YearsAtCompany*) risultano essere i soggetti maggiormente a rischio.
- **Dipartimenti:** L'analisi segmentata per dipartimento ha rivelato che, specialmente nell'area R&D, chi abbandona l'azienda tende ad avere un reddito mensile inferiore e un'età media più bassa rispetto a chi resta.

Tali osservazioni preliminari hanno guidato le successive fasi di pre-processing, confermando la necessità di integrare dati comportamentali per migliorare la capacità predittiva dei modelli.

4.2 Data Preprocessing e Cleaning

Il dataset iniziale è stato aggregato partendo da cinque fonti distinte: dati anagrafici generali, survey sui dipendenti, survey sui manager e log temporali di ingresso/uscita. In fase preliminare, sono state rimosse le variabili a varianza zero (EmployeeCount, StandardHours, Over18), in quanto costanti per tutti i dipendenti e quindi prive di potere predittivo. Per la gestione dei valori mancanti (Missing Values), è stata adottata una strategia differenziata per preservare la distribuzione statistica originale:

(1) **Variabili numeriche:** i valori nulli sono stati imputati utilizzando la mediana, una misura robusta che, a differenza della media, non viene influenzata dalla presenza di outlier.
(2) **Variabili categoriche:** i valori mancanti sono stati sostituiti con la moda (il valore più frequente) della rispettiva colonna.

4.3 Advanced Feature Engineering

Per arricchire il dataset informativo e catturare le dinamiche comportamentali dei dipendenti, sono state derivate nuove variabili sintetiche a partire dai file grezzi di Time Tracking (in_time e out_time). Le feature generate includono:

- **HoursPerDay (Intensità lavorativa):** calcolata come la media delle differenze tra orario di uscita e orario di ingresso per ogni giornata lavorativa valida, escludendo i giorni di ferie o assenza.
- **LongestAbsence (Discontinuità):** è stato implementato un algoritmo specifico per analizzare la sequenza temporale delle presenze, identificando il numero massimo di giorni consecutivi di assenza per ciascun dipendente. Questa metrica serve a intercettare pattern di disimpegno progressivo.
- **WorkOffHours (Disallineamento orario):** una metrica di conformità che conteggia la frequenza con cui un dipendente inizia il turno in orari anomali (prima delle 9:00 o dopo le 11:00) o termina fuori standard (prima delle 16:00 o dopo le 19:00). Questo indicatore punta a rilevare flessibilità eccessiva o potenziale stress da straordinari.

Infine, tutte le fonti dati sono state unite in un unico DataFrame analitico utilizzando l'EmployeeID come chiave primaria.

4.4 Experimental Setup e Modeling

Il dataset finale è stato suddiviso in set di addestramento (70%) e di test (30%) utilizzando un campionamento stratificato per mantenere la proporzione della classe target (Attrition). Prima dell'addestramento, è stata applicata una trasformazione dei dati tramite **ColumnTransformer**:

- **One-Hot Encoding:** per le variabili categoriche nominali.
- **Standard Scaling:** per le variabili numeriche, essenziale per garantire la convergenza di algoritmi basati sulla distanza come SVM e KNN.

Sono stati addestrati e confrontati sei diversi algoritmi di classificazione: Logistic Regression, Support Vector Machine (SVM), K-Nearest Neighbors (KNN), Decision Tree, Random Forest e XGBoost. La valutazione delle performance non si è limitata alla sola Accuracy (spesso ingannevole in dataset sbilanciati), ma ha incluso Precision, Recall, F1-Score e l'area sotto la curva ROC (AUC-ROC). Infine, per garantire l'interpretabilità dei risultati, è stato utilizzato l'approccio **SHAP** sul modello più performante, permettendo di isolare il contributo marginale di ogni feature sulla probabilità di abbandono.

5 Analisi dei risultati ottenuti

In questa sezione vengono presentati i risultati dell'analisi esplorativa, le performance dei modelli predittivi e l'interpretazione dei fattori chiave che influenzano il turnover, validando l'efficacia delle feature ingegnerizzate.

5.1 Analisi Esplorativa dei dati

L'analisi preliminare ha permesso di identificare correlazioni significative tra le variabili demografiche/lavorative e la decisione di abbandonare l'azienda.
Inizialmente, l'analisi della matrice di correlazione ha evidenziato come alcune variabili numeriche siano fortemente interconnesse (multicollinearità), ma ha anche mostrato correlazioni preliminari con il target.

Figure 1: Correlation Matrix

Successivamente, l'analisi bivariata ha fatto emergere pattern comportamentali distinti. Attraverso l'uso di Violin Plots, è stato possibile osservare la distribuzione congiunta di età, reddito e frequenza dei viaggi rispetto all'attrition:

(1) **Business Travel**: i dipendenti che viaggiano frequentemente ("Non-Travel" vs "Travel_Frequently") mostrano tassi di abbandono sensibilmente più alti. In particolare, tra chi viaggia spesso, coloro che abbandonano tendono ad essere più giovani e con un reddito mensile inferiore rispetto a chi resta.

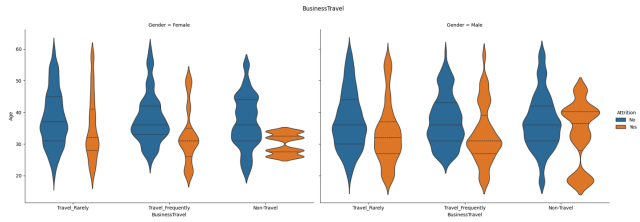

Figure 2: BusinessTravel x Age x Gender

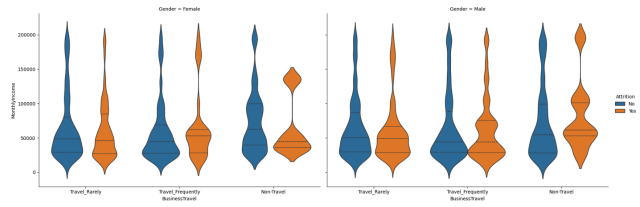

Figure 3: BusinessTravel x MonthlyIncome x Gender

(2) **Stato Civile e Anzianità:** i dati confermano che i dipendenti "Single" e quelli con una bassa anzianità aziendale (YearsAtCompany) sono i più vulnerabili al turnover.

Queste osservazioni preliminari hanno confermato l'ipotesi che il turnover non sia casuale, ma guidato da una combinazione di stress lavorativo (viaggi), fase della vita (età/stato civile) e soddisfazione economica.

5.2 Valutazione dei Modelli Predittivi

Sono stati addestrati e confrontati sei algoritmi di classificazione. È fondamentale notare che, data la natura sbilanciata del problema (la classe "Yes" è minoritaria), l'Accuracy da sola non è una metrica sufficiente; pertanto, è stato dato peso prioritario all'F1-Score e all'AUC-ROC.

Dall'analisi dei report di classificazione:

- **Logistic Regression e SVM**: Sebbene abbiano raggiunto un'accuratezza rispettabile (circa 86-90%), hanno mostrato limiti nel richiamo (Recall) della classe minoritaria, faticando a identificare correttamente tutti i dipendenti a rischio.
- **Random Forest e XGBoost**: Hanno ottenuto le prestazioni migliori in assoluto, con un'accuratezza prossima al 98-99% e un F1-Score molto elevato. Questi modelli sono riusciti a minimizzare sia i falsi negativi (dipendenti a rischio non rilevati) sia i falsi positivi.

La superiorità di questi modelli è confermata visivamente dalle curve ROC, dove XGBoost e Random Forest presentano un'area sotto la curva (AUC) quasi unitaria, indicando una capacità di discriminazione quasi perfetta.

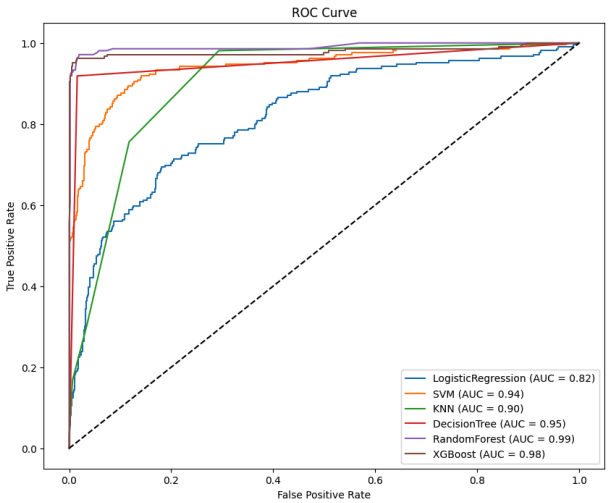

Figure 4: ROC Curve

5.3 Analisi dell'importanza delle feature

Uno degli obiettivi principali dello studio era comprendere quali variabili guidano le predizioni del modello Random Forest. L'analisi della Feature Importance ha rivelato una gerarchia chiara tra i fattori strutturali e quelli comportamentali.

Come si evince dal grafico sottostante, le variabili dominanti risultano essere quelle legate alla stabilità anagrafica e professionale: Age, TotalWorkingYears e MonthlyIncome occupano le prime posizioni. Questo suggerisce che i dipendenti più giovani, con meno esperienza e stipendi più bassi, sono strutturalmente più propensi a lasciare l'azienda.
Tuttavia, tra le variabili ingegnerizzate dai log temporali (Metodologie - 4.2), spicca l'importanza di HoursPerDay (media ore lavorate), che si posiziona come un predittore rilevante, confermando che l'intensità del carico di lavoro quotidiano è un driver critico. Al contrario, la variabile LongestAbsence risulta avere un peso marginale (in fondo alla classifica). Questo risultato è interessante perché indica che le lunghe assenze (probabilmente ferie pianificate o congedi giustificati) non sono necessariamente un segnale di disimpegno o preavviso di dimissioni, a differenza del sovraccarico quotidiano misurato dalle ore lavorate.

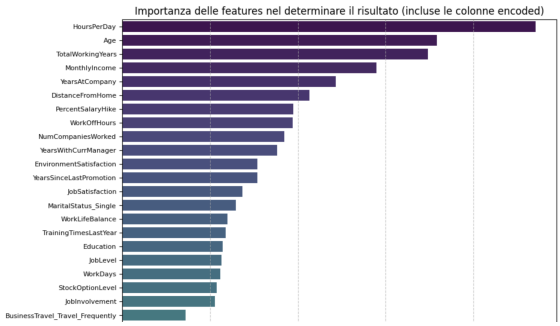

Figure 5: Feature Importance

5.4 Interpretabilità del modello

Per superare il limite della "Black Box" e fornire indicazioni azionabili al management, è stata condotta un'analisi SHAP. Il Summary Plot seguente offre una vista granulare dell'impatto di ogni feature:

- **Interpretazione dei colori:** i punti rossi indicano valori alti della feature, i punti blu valori bassi.
- **Impatto sull'output:** i punti a destra dell'asse centrale indicano un aumento della probabilità di abbandono.

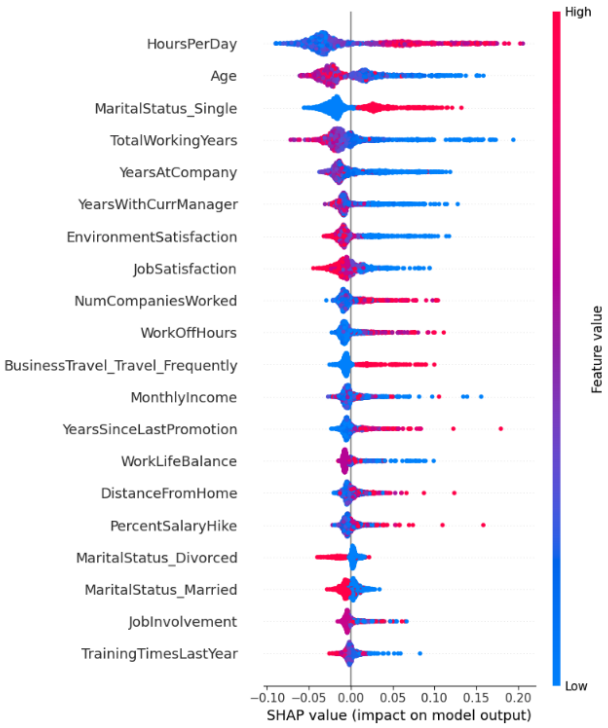

Figure 6: Analisi SHAP

Dall'analisi del grafico SHAP emergono conclusioni operative chiare:

- **HoursPerDay:** Si osserva una forte concentrazione di punti rossi verso destra. Ciò significa che all'aumentare delle ore medie lavorate, aumenta drasticamente la probabilità di abbandono. Questo suggerisce un problema di burnout.
- **Age e TotalWorkingHours:** I valori bassi (punti blu) sono correlati positivamente con l'attrition. I dipendenti più giovani e con meno esperienza sono i più volatili.
- **YearsWithCurrentManager:** Relazioni brevi con il manager corrente sono associate a un rischio maggiore, evidenziando l'importanza della stabilità relazionale e della leadership.

6 Conclusioni

Questo studio ha dimostrato come l'applicazione di tecniche avanzate di Machine Learning, unite a un'attenta ingegnerizzazione delle feature comportamentali, possa fornire strumenti predittivi efficaci per mitigare il fenomeno del turnover aziendale.

6.1 Sintesi dei risultati

L'approccio proposto ha superato i limiti dei modelli statistici tradizionali. Mentre la Regressione Logistica ha fornito una baseline accettabile, l'utilizzo di modelli Ensemble come Random Forest e XGBoost ha permesso di raggiungere performance eccellenti (Accuracy > 98% e AUC prossima a 1.0). Il valore aggiunto critico di questo lavoro risiede nell'elaborazione dei log di Time Tracking. L'introduzione della variabile HoursPerDay ha rivelato che il carico di lavoro effettivo è uno dei predittori più forti dell'abbandono, spesso superiore a variabili anagrafiche classiche. Al contrario, metriche come LongestAbsence si sono rivelate meno determinanti, suggerendo che le assenze prolungate (se giustificate) non sono necessariamente sintomo di disaffezione.

6.2 Implicazioni Manageriali

Dall'analisi SHAP emergono indicazioni operative chiare per il management di XYZ:

(1) **Prevenzione del Burnout:** La forte correlazione tra ore lavorate e rischio di abbandono suggerisce l'urgenza di monitorare gli straordinari strutturali. Interventi mirati sulla ridistribuzione dei carichi di lavoro potrebbero ridurre drasticamente l'attrition.
(2) **Retention dei Giovani Talenti:** I dipendenti più giovani (Age) e con minore anzianità lavorativa (TotalWorkingYears) sono i più volatili. È consigliabile implementare programmi di mentorship e percorsi di carriera chiari per questo segmento demografico.
(3) **Stabilità della Leadership:** L'importanza della variabile YearsWithCurrManager evidenzia che la continuità relazionale con il proprio responsabile è un fattore protettivo. Investire sulla formazione dei manager e sulla stabilità dei team è una leva strategica fondamentale.

6.3 Sviluppi futuri

Nonostante i risultati promettenti, lo studio presenta margini di miglioramento. Attualmente, l'analisi è statica. Sviluppi futuri potrebbero includere:

- **Analisi Time-Series:** Trasformare il problema in una previsione temporale (Survival Analysis) per stimare non solo se, ma quando un dipendente lascerà l'azienda.
- **Analisi testuale (NLP):** Integrare dati non strutturati, come i commenti liberi nelle survey di soddisfazione o le interviste di uscita, per catturare il "sentiment" qualitativo che i dati tabulari non possono mostrare.
- **Deployment:** Sviluppare una dashboard interattiva per l'ufficio HR che segnali in tempo reale i dipendenti a rischio, permettendo interventi proattivi prima che la decisione di lasciare l'azienda diventi irreversibile.

References

(1) Kaggle: https://www.kaggle.com/datasets/vjchoudhary7/hr-analytics-case-study
(2) How Employee Attrition Affects the Workplace: https://www.intoo.com/us/b attrition/
(3) The Real Cost of Replacing an Employee: https://bloomfire.com/blog/cost-of-replacing-an-employee/
(4) The Hidden Impact of Attrition on Workplace Productivity: https://www.plumhq.com/blog/impact-of-attrition-on-productivity
(5) The Hidden Costs of Employee Attrition and How to Address Them: https://group.teamlease.com/the-hidden-costs-of-employee-attrition-and-how-to-address-them/
(6) Attrition rate: What it is and how to reduce it effectively: https://www.culturemonkey.io/employee-engagement/attrition-rate/